

预测日际变温而非气温

多站点欧洲气象数据集上的“评估优先”问题形式化

黄浩然 (Huang Haoran)

2026 年 9 月

摘要

在站点密集的气象数据集上，次日近地面气温预报很容易“因为错误的理由”取得很高的分数：日际持续性加上季节循环共同解释了原始气温序列超过 90% 的方差，因此任何模型都会白捡这份技能，却并未学到任何气象知识。本文针对一个公开的欧洲多站点数据集（18 站、2000 - 2010 年、163 个特征）重新定义预测任务，改为预测巴塞尔日最高温的日际变化 $\Delta T_{\max}(t+1) = T_{\max}(t+1) - T_{\max}(t)$ 。在这一目标空间里，持续性预报恒等于零，因此相对“零变化”基线的技巧值衡量的是气象学习能力，而不是日历知识。我们按阶梯拟合了一组模型——三个朴素基线、闭式解岭回归与 L1 正则最小二乘，以及一个小型多层感知机——全部采用严格按时间切分（训练 2000 - 2007、验证 2008、测试 2009）、预处理统计量仅由训练期估计、7 天分块的移动块 bootstrap 不确定性估计。所有学习模型都显著优于零变化基线（测试 MAE 2.393 °C）：岭回归 1.827 °C（技巧 +23.7%）、Lasso 1.773 °C（+25.9%）、MLP 集成 1.751 °C（+26.9%）；而学习模型之间的差异均落在 bootstrap 噪声之内。消融实验表明：信号是分布式的而非集中于少数预测因子；信号由气压场与上游站点变化承载，符合中纬度平流图像；若仅使用目标站自身的观测，信号完全消失。把 18 个站点池化进一个全局模型，比 18 个独立模型差 0.36 °C MAE——这个负面结果为该样本量下共享表示的价值划出了上界。

1 引言

公开气象数据集很容易诱发一个看似简单的基准题：用今天的观测预测明天的温度。在本文所用的数据集上——18 个欧洲站点、跨度十一年的逐日站点观测——朴素规则“明天等于今天”对原始日均温就能在测试期达到 MAE 1.667 °C、 $R^2 = 0.9206$ 。该序列方差的另外 74.4% 又能被月度气候均值单独解释。因此，任何回归模型——无论多么简单——都能在原始目标上刷出很高的精度，而这个数字证明的是日历与大气持续性，不是模型本身。

本文把“表面技巧”与“真实技巧”之间的落差当作研究对象本身。我们重新定义任务，使那些平凡预报在构造上就一文不值，然后追问：机器学习模型究竟能否榨出残余信号？重新定义后的目标是巴塞尔日最高温的日际变化 $\Delta T_{\max}(t+1)$ 。在这个空间里持续性预报恒为零，技巧必须来自别处。探索性分析指出了线索所在：去除季节循环后，上游站点（马斯特里赫特、图尔、德比尔特）的当日观测与巴塞尔次日气温变化的相关系数达 0.35 - 0.40，这与中纬度西风带中的暖平流与冷平流一致。

本文有两项贡献。其一是一套问题形式化：把持续性从模型手里移出、放进评价里，并配以一套评估协议（严格按时间切分、统计量仅用训练期、分块 bootstrap 置信区间），使报告中每一个数字都可被解读（见第 3 节）。其二是在该形式化上做一组受控实验：从朴素基线、经正则化线性模型到小型 MLP 的阶

梯，外加特征消融与多站点扩展实验（第 4-5 节）。模型刻意保持简单；目的在于度量这个问题本身含有多少技巧，而不是刷排行榜。

2 数据集

本文使用 Huber 等人发布的气象预测数据集（MIT 许可），其原始观测来自欧洲气候评估数据集（ECA&D），采用 release commit `83d70ee`。主表覆盖 2000-01-01 至 2010-01-01 共 3654 个连续日、18 个欧洲站点，含 `DATE`、`MONTH` 两列与 163 个特征：18 站 $\times$ 11 个变量（温度、湿度、气压、风、辐射、日照、云量、降水），其中站点一变量理论格子共 198 个，35 个整体缺失（例如 `wind_gust` 只有 7 个站点有；巴塞尔既不报风速也不报阵风）。

必须声明的上游加工

这份发布数据“干净”只是加工的结果。缺失率超过 5% 的列被整列删除；缺失率不超过 5% 的列由数据集作者用**均值填补**。两种操作上游都有文档说明，且都会影响建模：均值填补会压缩方差、抬高受影响列的相关性；整列删除则抹掉了真实但稀疏的信息（例如阵风）。量纲异质是刻意保留的——气压以 1000 hPa 为单位（总体标准差仅 0.013），湿度取值于 $[0, 1]$ ，阵风最大 41 m/s——因此任何基于距离或梯度的模型都必须标准化。

物理不可能性审计

由于上游用填补而非标记来“处理”缺陷，我们按物理取值范围逐格审计了全部单元格，发现 77 个不可能值（占 595,602 个单元格的 0.013%）：`STOCKHOLM_cloud_cover` = -99（哨兵残留）、斯德哥尔摩 29 天日照为负、3 个斯德哥尔摩气压 -0.099、1 个图尔气压 0.0003，以及 41 天 `temp_min` 大于 `temp_max`（希思罗 40 天、罗马 1 天）。损害集中在两个站点而非均匀散布，且有一个缺陷格（斯德哥尔摩云量，2009-06-25）落在测试期内。若不处理，差分会把哨兵值变成 $\pm 100^\circ\text{C}$ 的假尖刺；第 4.1 节在任何差分之前先处理掉全部 77 格。

统计结构

三条事实驱动了后续全部设计。(i) 巴塞尔日均温的月度气候均值解释其方差的 74.4%；去季节化异常的一阶自相关为 0.819，而**日际变化**的一阶自相关仅 0.075，接近白噪声。(ii) 特征矩阵高度冗余：163 个特征中有 62 个落在 $|r| > 0.95$ 的相关对里（最大 0.996，出现在两个相邻站的气压之间）。(iii) 跨站点信息是唯一可能的增量信号来源：去除月度循环（气候量仅用训练年份估计）后，马斯特里赫特与图尔的当日观测与巴塞尔次日气温变化相关 0.35 - 0.40，而巴塞尔自身当前变化的相关只有 0.075。

3 问题形式化

3.1 三个候选目标，三种难度地板

对一条气温序列而言，“预测问题”会随预测对象的不同而发生质变。表 1 汇总三个候选目标。

表 1 巴塞尔次日气温预测的三个候选目标，以及“高分”在每个目标上究竟证明了什么。持续性与气候值均在 3.5 节定义的测试窗口上计算。

目标	季节循环占比	持续性测试成绩	高分证明的是
原始 $T_{\text{mean}}(t+1)$	方差的 74.4%	MAE 1.667 °C ($R^2 = 0.9206$)	日历 + 惯性
去季节化异常	(设计上已剔除)	RMSE 2.288 °C	异常持续性
$\Delta T_{\text{max}}(t+1)$	构造上 ≈ 0	MAE 2.393 °C (零变化)	气象学 (如果还有的话)

预测原始值被两种“免费”技巧主导。预测异常剔除了日历，却留下异常持续性，而持续性预报已经把它拿走了（持续性 2.288 对气候距平零假设 3.378 °C RMSE，来自本文的形式化探针）。预测变化则把两份免费午餐同时剔除。代价是要诚实地承认难度：日际变化接近白噪声（一阶自相关 0.075），可达技巧远低于原始气温成绩所暗示的水平。对于一个研究对象是“模型技巧”而非排行榜准确率的工作，我们认为这是正确的取舍。

3.2 形式化定义

令 $x_t \in \mathbb{R}^{163}$ 表示第 t 天全部 18 个站点的原始观测，并附加 4.2 节描述的工程特征块。目标为

$$y_t = \Delta T_{\text{max}}^{\text{BASEL}}(t+1) = T_{\text{max}}^{\text{BASEL}}(t+1) - T_{\text{max}}^{\text{BASEL}}(t), \text{ 式 (1)}$$

我们通过最小化经验风险 $(1/n) \sum_t \ell(f(x_t), y_t)$ 学习 $f: \mathbb{R}^p \rightarrow \mathbb{R}$ ，其中 ℓ 取平方误差（线性模型）或 Huber 损失（MLP），并可加惩罚项。之所以用 T_{max} ，是因为它 18 站齐全，而 temp_min 缺布达佩斯。

3.3 等价性论证：把持续性移进评价

预测 ΔT_{max} 而不是 $T_{\text{max}}(t+1)$ ，并非声称函数类不同。当 $T_{\text{max}}(t)$ 本身就在输入里时，任何对明天气温的预测器减去该输入即可变成对变化的预测器，反之亦然：两个任务共享同一假设空间。改变的是评价。在气温水平空间里最强基线是持续性 $\hat{T}(t+1) = T(t)$ ，模型要against 它打分；在变化空间里持续性预报恒为零，持续性技巧被构造性地从每个模型中移除。一个只是复制 $T_{\text{max}}(t)$ 的模型在我们的空间里得分 MAE 2.393 °C（零变化基线），在水平空间里则是 1.667 °C；这种形式化让差异直接体现在指标本身，而不必藏在读者必须记得去查的基线对比里。

3.4 已否决的任务形式

我们考虑并否决了四个替代任务。次日原始气温受持续性污染，且已被该数据集自带的教学 notebook 与公开 Kaggle kernel 覆盖。日照时长回归是那些 notebook 的主实验。野餐适宜性与月份分类是派生标签：野餐标签是一条确定性规则（“无雨且暖”），有一个站点恒为 False，且其逐月正例率相差 120 倍，随机划分会把任务退化成猜日历。降水量回归每站 35 - 75% 为零，需要本章范围放不下的 hurdle 式处理。次日降水发生是有价值的低技巧分类扩展，但出于同样的篇幅原因留待后续。

3.5 评估协议

切分。原始日温一阶自相关 0.957，任何随机划分都会泄漏。本文使用唯一的固定时间切分：训练 2000–2007（2922 天；对齐后 2920 个样本）、验证 2008（366）、测试 2009-01-01 至 2010-01-01（366；最后一天只是一个边界日，故该窗口实质为 2009 日历年加一天）。所有模型与超参选择由验证年份裁决；每个最终配置在测试年上只评估一次。

统计量仅用训练期。清洗阈值、填补中位数、标准化参数、月度气候均值与正则化强度，全部只在 2000–2007 上估计，再原样施加到 2008 与 2009。

指标。主指标为 MAE ($^{\circ}\text{C}$)，因为目标分布重尾（锋面过境产生 $|\Delta T_{\max}| > 10^{\circ}\text{C}$ ）。另报 RMSE、变化空间的 R^2 、预测变化与实测变化的 Pearson 相关（近常数预报下无定义，记为“—”），以及

$$\text{技巧 skill} = 1 - \text{MAE}_{\text{模型}} / \text{MAE}_{\text{零变化}}, \text{ 式 (2)}$$

即相对零变化基线的 MAE 相对降幅。全文以技巧为首要数字。

不确定性。测试窗口 366 天， 0.1°C 量级的 MAE 差异已接近噪声（该样本量下 MAE 标准误 $\approx 0.17^{\circ}\text{C}$ ）。所有区间为移动块 bootstrap 95% 置信区间，分块长度 7 天（天气系统记忆约 3–5 天，7 天块可去相关），1000 次重采样，固定随机种子。模型之间的差异使用**同块配对** bootstrap，这比比较两条相互重叠的边际置信区间灵敏得多。

4 模型

4.1 数据管线

所有模型共用一条管线，顺序为：(1) 按物理范围把 77 个缺陷格掩蔽为 NaN，先于任何差分，以免哨兵值在 Δ 特征中变成 $\pm 100^{\circ}\text{C}$ 的假尖刺；(2) 用训练年份估计的“按站点、按日历月”中位数填补被掩蔽与缺失的单元格；(3) 特征构造（4.2 节）；(4) 用训练集均值与标准差标准化；(5) 模型阶梯（4.3 节）；(6) 按 3.5 节协议评估。掩蔽步骤精确复现探索性审计的 77 格，这同时充当管线的回归测试。

4.2 特征块

我们从填补后的 163 列表构造四个特征块：

- **levels (163)：**第 t 天全部观测，标准化。
- **deltas (163)：**同一批列的一日差分 ($x_t - x_{t-1}$)；变化特征承载天气系统信号。
- **grads (7)：**七个上游站的气压减去巴塞尔气压，作为地转风 / 平流代理。上游集合 {马斯特里赫特、图尔、杜塞尔多夫、明兴、卡塞尔、德比尔特、希思罗} 由一个领先相关探针确定（次日异常相关 0.69–0.80；前六位按相关排名，希思罗按西风带上游位置入选），且在本文任何模型拟合之前就已固定。
- **受控项，默认关闭：**日序 $\sin/\cos(2)$ 与缺失指示 (163)。它们只作为消融实验臂存在（5.3 节）；主配置不含它们，以免日历信息从后门进入。

主输入为 levels + deltas ($p = 326$)；加上 grads 得 $p = 333$ 。另有两个缩减输入供消融：上游 7 站子集（14 列：上游 $T_{\max}$ 的水平与差分）与本站点对（巴塞尔 $T_{\max}$ 的水平与差分， $p = 2$ ）。

4.3 模型阶梯

基线。零变化： $\hat{y} = 0$ ，即翻译到变化空间的持续性预报，是式 (2) 的及格线。昨日 Δ ： $\hat{y}_t = \Delta T(t)$ ，重复今天的变化；它应当失败，其失败恰好记录了变化序列没有可利用的自相关。月度 Δ 气候值：训练期按日历月的平均变化；它应当落在零技巧附近。

岭回归（闭式解）。对每个特征集，我们精确求解

$$\hat{w} = \operatorname{argmin}_w (1/n) \|Xw - y\|_2^2 + \alpha \|w\|_2^2 = (X^T X + \alpha I)^{-1} X^T y, \quad \text{式 (3)}$$

求解通过 `torch.linalg.solve` 完成——无迭代轮数、无收敛担忧、精确到机器精度。唯一超参 α 在跨 10^{-2} 至 10^4 的 25 点对数网格上按 2008 验证 MAE 选取。训练样本 2920、 $p \leq 333$ 时求解瞬时完成，这让整套消融程序既廉价又完全可复现。

Lasso (L1, 梯度训练)。 $\min_w (1/n) \|Xw - y\|_2^2 + \alpha \|w\|_1$ ，用 Adam 优化 (200 轮)， α 在 $[10^{-3}, 1]$ 的 8 点几何网格上按 2008 选取。Lasso 承担两个作用：作为第二种正则族对岭回归做稳健性检验，以及提供一张“哪些物理通道能在稀疏压力下存活”的可解释地图。

MLP（容量上限探针）。一个小型前馈网络：隐藏层规模 {32}、{64, 32} 或 {128, 64}；GELU 激活；dropout $\in \{0.2, 0.4\}$ ；权重衰减 $\in \{10^{-4}, 10^{-3}\}$ （共 12 个配置）。训练用 Huber 损失（目标按训练期 σ_Δ 标准化后 $\delta = 1$ ）、Adam (lr 10^{-3} , batch 64)，并在验证 MAE 上早停（耐心 30，最多 300 轮）。每个配置用三个固定种子 {0, 1, 2} 训练；配置按**平均验证 MAE** 选出，报告的测试数字取三个种子预测的均值（集成）。MLP 的角色被明确限定：在约 2.9k 训练样本与低信噪比下，它探测容量能否在线性解之外带来增益，而零结果是发现而非失败。

多站点池化扩展。把 18 站的变化序列堆叠成 65,736 个 station-day (18 $\times$ 3652 个对齐日；测试片 6588)，每个样本共享同一个全局 326 列特征场（第 t 天全部站点观测），目标则是各自站点的 $\Delta T_{\max}$ 。由于各站平均变化接近零，把各站池化在一起在变化空间里是物理上可接受的，而在水平空间里则从来不是。我们比较池化零变化基线、单一全局岭回归、单一全局 MLP，以及 18 个独立的按站岭回归。

实现。全部模型在 PyTorch (2.13, CUDA) 下用一个共享库实现；第 5 节每一个数字都由附录 A 列出的已提交脚本产出。所有随机种子固定 (bootstrap 种子 42；MLP 种子 0-2)。

5 实验

5.1 主要结果

表 2 是本文的规范结果表，图 1 给出阶梯的可视化。三点结论突出。

表 2 巴塞尔 $\Delta T_{\max}(t+1)$ 测试期结果（366 天，2009）。MAE 单位 $^{\circ}\text{C}$ ，括号为 95% 移动块 bootstrap 置信区间（7 天块、1000 次重采样）。技巧按式（2）定义。相关性为预测变化与实测变化的 Pearson 相关。

模型	MAE [95% CI] ($^{\circ}\text{C}$)	RMSE ($^{\circ}\text{C}$)	R^2	相关	相对零变化技巧
零变化（及格线）	2.393 [2.104, 2.680]	3.176	-0.000	—	—
昨日 Δ	3.447 [3.033, 3.916]	4.647	-1.141	-0.072	-44.0%
月度 Δ 气候值	2.393 [2.098, 2.682]	3.174	0.001	0.034	+0.0%
岭回归：仅 levels（163）	1.845 [1.651, 2.033]	2.383	0.437	0.665	+22.9%
岭回归：levels+ Δ （326）	1.827 [1.623, 2.014]	2.400	0.429	0.660	+23.7%
岭回归：levels+ Δ +grad（333）	1.829 [1.624, 2.012]	2.410	0.424	0.660	+23.6%
岭回归：上游 7 站子集（14）	2.056 [1.829, 2.284]	2.760	0.245	0.502	+14.1%
岭回归：仅本站（2）	2.392 [2.104, 2.675]	3.152	0.015	0.183	+0.0%
Lasso：levels+ Δ （326）	1.773 [1.574, 1.955]	2.365	0.445	0.671	+25.9%
MLP 集成（最佳配置）	1.751 [1.546, 1.946]	2.341	0.457	0.682	+26.9%




图 1 测试窗口（366 天）上的模型阶梯。柱高为测试 MAE ($^{\circ}\text{C}$)，须为 95% 分块 bootstrap 置信区间。灰色：朴素基线；蓝色：岭回归各变体；橙色：Lasso；红色：MLP 集成。虚线为零变化柱（2.393 $^{\circ}\text{C}$ ）。所有学习模型的置信区间均不与及格线重叠；三个学习模型彼此重叠。

第一，三个学习模型都显著优于零变化基线（配对 bootstrap 差异显著小于零，见表 3）：技巧是真实的，不是波动。第二，学习模型之间的差异并不显著。MLP 相对岭回归改进 0.076 $^{\circ}\text{C}$ ，95% 置信区间为 $[-0.149, 0.000]$ ——与“无线性之上的改进”一致。第三，信息比模型类别更重要：全量场相对上游 7 站子集有显著的 0.229 $^{\circ}\text{C}$ 优势，而仅用目标站自身观测只能得到 +0.0% 技巧。一个拿到正确信息的线性模型，胜过拿到子集信息的 MLP。




图 2 左：MLP 集成预测与实测 $\Delta T_{\max}$ （测试期，MAE 1.75 °C， $r = 0.68$ ）；模型能捕捉中等幅度变化，但收缩极端值——重尾目标下条件均值拟合的预期表现。右：测试期 2009 的逐月误差剖面；零变化基线（灰）与 MLP（红）都在冬季月份误差最大，而技巧差距也在那里最宽。

散点图（图 2 左）呈现重尾目标下条件均值拟合的预期特征：极端变化（ $|\Delta T_{\max}| > 6$ °C 的事件）被系统性低估。这并非 MLP 独有的缺陷——一个无法解析单次锋面过境驱动因子的模型，恰恰是通过收缩来最小化期望损失——但它给可达 MAE 设了上限，并引出季节分析：模型与基线都在冬季误差最大（图 2 右），因为那时 $\Delta T_{\max}$ 的方差最大。

5.2 配对显著性

表 3 测试 MAE 的配对分块 bootstrap 差值（A - B，单位 °C；负值表示 A 更优）。“显著”指 95% 置信区间不含零。

A - B	差值 (°C)	95% CI	显著
MLP - 零变化	-0.642	[-0.843, -0.467]	✓
Lasso - 零变化	-0.620	[-0.834, -0.416]	✓
岭回归(1v1+Δ) - 零变化	-0.566	[-0.769, -0.383]	✓
MLP - 岭回归(1v1+Δ)	-0.076	[-0.149, 0.000]	
MLP - Lasso	-0.023	[-0.119, 0.068]	
Lasso - 岭回归(1v1+Δ)	-0.054	[-0.101, 0.002]	
岭回归(1v1+Δ) - 岭回归(up7)	-0.229	[-0.367, -0.115]	✓

表 3 的读法刻意保守。MLP 对岭回归的区间上界恰好触零；因此我们把 MLP 描述为“与无线性之上的改进一致”，而不是宣称一个小胜。366 天的测试窗口下，小于约 0.1 °C 的效应无法分辨。

5.3 特征消融

表 4 特征集消融（协议相同；除注明外均为岭回归）。维数为输入列数。技巧相对零变化基线。

特征集	维数	MAE (° C)	技巧
仅 levels	163	1.845	+22.9%
仅 deltas	163	1.978	+17.4%
levels + deltas（主配置）	326	1.827	+23.7%
+ 气压梯度	333	1.829	+23.6%
+ 梯度 + 日序 sin/cos	335	1.834	+23.4%
+ 梯度 + 缺失指示	496	1.842	+23.0%
上游 7 站: levels + deltas	14	2.056	+14.1%
上游 7 站: 仅 deltas	7	2.115	+11.6%
上游 7 站: deltas + 梯度	14	2.075	+13.3%
本站: 水平 + 差分	2	2.392	+0.0%
Lasso 全量 (326), val 选 α	326	1.773	+25.9%
Lasso top-25 特征, 岭回归重拟合	25	1.859	+22.3%

表 4 传达四条信息。(i) levels 与 deltas 各自单独就承载了大部分信号，二者叠加增益有限（单独 22.9% 与 17.4%，合并 23.7%）：两个块很大程度上编码的是同一批天气系统。(ii) 两个受控实验臂表现正确：加入日序特征降低技巧（23.4% 对 23.7%），确认变化目标里没有日历免费午餐；缺失指示也无帮助（23.0%）。(iii) 气压梯度在全量场中是冗余的（+23.6% 对 +23.7%），但在上游子集内有价值（11.6% → 13.3%），即它携带部分重叠的物理信息。(iv) 稀疏压力保留了一个紧凑核心：在 Lasso 的 top-25 特征上重拟合岭回归，仍保留全量模型 23.7 个百分点技巧中的 22.3 个，说明存在一个可解释的“四分之一大小”模型——但在验证最优 α 下，Lasso 仍保留 326 个系数中的 324 个非零，对信号的诚实描述是**分布式**，而非“几个魔法特征”。

5.4 哪些物理通道？




图 3 绝对值最大的 15 个 Lasso 系数（标准化尺度）。蓝：正，橙：负。主导通道是巴塞尔、希思罗、蒙泰利马尔与图尔的气压变化，其次是上游湿度变化——一个与气压场、平流一致的签名。

图 3 给出绝对值最大的标准化 Lasso 系数：巴塞尔气压日变化（+0.28）、希思罗（-0.30）、蒙泰利马尔（+0.23）与图尔（-0.17），随后是上游湿度变化（马斯特里赫特 +0.13、德累斯顿 -0.12）。气压是环流变量，其局地倾向是气温变化的经典临近预报因子；上游站点气压倾向以交替符号进入，与天气尺度系统过境的图像一致。我们把这报告为拟合权重的**观测到的**签名，而非因果论断：在 326 个标准化且高度共线的输入下，单个系数并不可识别，因此正确的表述是“气压场主导了权重质量”。

5.5 MLP 网络

12 个配置的网络是平的：每个配置的测试集成 MAE 都落在 1.70 - 1.75 °C 之间。按验证选出的配置（隐藏层 64 - 32、dropout 0.4、权重衰减 10⁻⁴；平均验证 MAE 1.797 °C）给出逐种子测试 MAE 1.795 / 1.758 / 1.757 °C（种子标准差 0.018），集成 1.751 °C。从约 544 到约 1.2 万参数的不同容量之间如此平坦，本身就是结果：在当前样本量与噪声水平下，容量不是约束瓶颈；而且验证集选型协议保护我们不把“运气更好的网络”（某些未被选中的配置在测试集上曾取得 1.70）误当成更好的模型。

5.6 多站点扩展：一个负面结果

表 5 多站点扩展（测试期 6588 个 station-day，2009）。按站模型为 18 个在全量场上独立拟合的岭回归；池化模型为单一全局拟合、以各站为目标。

模型	MAE (° C)	95% CI	相对池化零变化技巧
池化零变化	2.187	—	—
按站岭回归（18 个模型，均值）	1.705	[1.299, 1.998] [†]	+22.0%
池化岭回归（单一全局模型）	2.066	[2.016, 2.115]	+5.5%
池化 MLP	2.038	[1.986, 2.088]	+6.8%

[†] 该区间是各站之间的取值范围，不是 bootstrap 置信区间。




图 4 各站测试 MAE（每站 366 天）：零变化基线（灰）对比按站独立岭回归（蓝），按基线难度排序。18 个站技巧全为正，且各站基线难度差异显著。

池化失败了，而且失败得有信息量：单一全局岭回归比 18 个独立模型差 0.36 ° C（2.066 对 1.705，远超置信区间），池化 MLP 只收回一部分差距（2.038）。可能的机制是站点特异性——各站的变化序列对同一天气尺度系统的响应不同（坡向、海拔、大陆性），单一线性映射无法表达 18 个不同的响应向量；带交互项的非线性模型能缓解但无法消除这种不匹配。我们原本预期池化会有帮助（变化空间消除了各站气候态），数据却给出否定答案；诚实的报告是把这个反驳连同机制假设一起写出，而不是悄悄把实验丢掉。

6 讨论与局限

可预报性天花板。三个学习模型聚集在 24 - 27% 技巧，差异在统计上不可分辨。我们把这一平台解释为任务的性质而非模型的性质：一旦把持续性与日历从目标中移除，剩余方差大多是天尺度（synoptic）噪声在日提前预报上的可预报性上限，而约 25% 的 MAE 降幅就是现有信息支持的水位。昨日 Δ 基线的惨败

(-44%) 与仅本站模型的 +0.0% 则划定了信号边界：它存在于空间场中，尤其是气压场，而不在目标自身的历史里。

样本量与容量的权衡。在 2920 个训练样本与低信噪比下，MLP 相对精确线性解的优势落在噪声之内。这正是 MLP 被设计来暴露的“样本量—容量”权衡，是一个合法的实验结论。我们没有尝试更深或更宽的络，因为验证准则不支持：网格已显示验证 MAE 没有偏向容量的梯度，而在早停之下增加参数无法制造出线性解看不见的信号。

上游加工对这些数字做了什么。数据集对稀疏列的均值填补会压缩方差、抬高恰好是这些列的相关性；我们对 77 个审计格所做的是掩蔽之后第二次按站点按月的填补中位数。原则上两者都不无害，但它们只作用于不超过 0.1% 的单元格，且消融显示这些列并非决定性的（主导通道气压在 18 站中的 15 站完整观测）。测试期唯一的缺陷格（斯德哥尔摩云量）在差分前已被掩蔽，因此没有任何单个损坏单元格能左右报告中的数字。

统计功效。366 天的测试窗口限定了可主张的范围：小于约 0.1°C 的效应无法分辨，MLP 对岭回归那个临界的区间正应如此解读。多站点堆叠（6588 个 station-day）功效更大，但它回答的是另一个问题（站点响应异质性）；我们宁可选一个更小更干净的结论，也不愿采用一个其假设已被数据否决的池化数字。

效度威胁。(i) 所有预处理统计量仅用训练期，但特征构造（上游集合、一天差分窗口）是在探针实验看过同一测试年之后才固定的；探针用的是异常空间的 RMSE 且未做测试集模型选择，但一个完全留出的区域会更干净。(ii) 单一目标站、单一测试年；逐站分析（图 4）部分缓解了跨站点的普适性，但未覆盖跨年份。(iii) 18 站的 $T_{\max}$ 是同质化后的 ECA&D 产品，上游质量控制按既定事实接受。

可扩展方向。多步长技巧衰减 ($h = 1 \cdots 10$) 可以定量刻画可预报性边界；次日降水发生是同一协议下自然的低技巧分类扩展；把池化模型换成站点条件嵌入（共享主干 + 各站独立输出头）是 5.6 节负面结果的直接后续。

7 结论

我们把次日气温预测重新形式化为日际变化预测，从奖励函数中移除持续性与季节循环，并把零变化预报显式设为及格线。在严格时间切分、统计量仅用训练期、含分块 bootstrap 不确定性的协议下，一组刻意简单的模型在测试年上相对该及格线取得 24–27% 的 MAE 技巧：岭回归 1.827°C 、Lasso 1.773°C 、MLP 集成 1.751°C ，而零变化基线为 2.393°C ；所有学习模型相对零变化的改进都显著，学习模型之间的差异都在噪声之内。信号是空间性的、以气压为主导，符合中纬度平流的图像；从目标站自身看不到它；它也无法在跨站之间朴素地池化。这一形式化的价值在于：上述每一条陈述都是一个带区间的可证伪数字，而不是一个持续性预报同样能刷出来的高 R^2 。

声明

数据可得性。数据集为公开（MIT 许可）：github.com/florian-huber/weather_prediction_dataset，release commit [83d70ee](https://github.com/florian-huber/weather_prediction_dataset/commit/83d70ee)，Zenodo 存档 [doi:10.5281/zenodo.7525955](https://doi.org/10.5281/zenodo.7525955)。全部代码、每次实验的记录与机器可读结果均随附于配套仓库；附录 A 给出确切命令。

AI 辅助披露。分析代码与本稿件由作者在 AI 编码助手（OpenCode，GLM）协助下完成；报告中的每个数字都由已提交的脚本生成，其输出保存在仓库中，作者已逐项核对。

资助 / 利益冲突。无。本报告作为研究任务评估作品完成。

参考文献

[1] Klein Tank, A. M. G., 等（2002）。20 世纪地表气温与降水逐日数据集，服务于欧洲气候评估。International Journal of Climatology, 22, 1441–1453.

[2] Huber, F., van Kuppevelt, E. D., Steinbach, P., Sauzé, C., Liu, Y., Weel, B.（2023）。Will the sun shine? — An accessible dataset for teaching machine learning and deep learning. Proceedings of the Third Teaching Machine Learning and Artificial Intelligence Workshop, PMLR 207, 27–31.

附录 A 可复现性

环境。Python 3.12（Windows）；PyTorch 2.13（CUDA）、NumPy、pandas；scikit-learn 仅用于探索阶段。全程无随机划分；随机种子如 4.3 节所述固定。

一键复现。把数据集 CSV 放入 `data/` 后，在仓库根目录执行：

```
python analysis/eda.py           (数据审计；项目记录中的图 1–9)
python analysis/r1_baselines.py   (管线回归测试；基线表)
python analysis/r2_lasso_ablation.py (表 4；图 3 的数据)
python analysis/r3_mlp.py         (MLP 网络，5.5 节；池化表)
python analysis/r4_eval_figures.py (表 2–3；图 1–4)
bash reproduce_all.sh             (一次跑完全部步骤)
bash report/build.sh              (重建本中文版 PDF 与英文版 PDF)
```

每个脚本把自己的表写入 `docs/*.csv`；本报告的每个数字都能追溯到这些文件之一，而 `docs/progress/` 下的逐次实验记录（含被放弃的方向）记载了每一次设计决策。

数据归属。原始观测来自 ECA&D 站点数据 [1]；数据集与教学背景见 Huber 等人 [2]。上游加工（缺失率 >5% 整列删除、≤5% 均值填补、只缩放不标准化单位）已在第 2 节声明。

本中文版为英文报告 `report.pdf` 的完整对照译本，仅供作者内部理解与答辩准备使用；所有数字与英文版逐项一致。正式提交以英文版为准。