

预测单站日际最高温差 来自 18 个欧洲站点的证据

黄浩然 (Huang Haoran)

2026 年 9 月

摘要

在站点密集网络上做的次日气温预报，容易因为错误的理由而显得很漂亮。日际持续性与年循环合起来解释了原始气温序列超过 90% 的方差，模型只要继承这两份技巧就能交出好成绩，却并没有学到任何关于大气的知识。本文针对一个公开的欧洲多站点数据集（18 站、2000 - 2010 年、163 个特征）重新定义问题，改为预测巴塞尔日最高温的日际变化 $\Delta T_{\max}(t+1) = T_{\max}(t+1) - T_{\max}(t)$ 。在这个目标空间里，持续性预报恒等于零，因此相对零变化基线的技巧值度量的是气象信息，而不是日历知识。一组阶梯式模型在严格按时间的切分下拟合（训练 2000 - 2007、验证 2008、测试 2009），预处理统计量只用训练期估计，不确定性用移动块 bootstrap 给出。所有学习模型都显著越过零变化这条及格线（测试 MAE 2.393 °C）：岭回归 1.827 °C，Lasso 1.773 °C，MLP 集成 1.751 °C，而三者彼此的差异落在 bootstrap 噪声之内。消融把可用的信号定位在目标站之外：目标站自身的温度观测贡献 +0.0% 技巧。信号摊在整个空间场上，而不是集中在少数几个通道上，拟合出的权重质量落在气压特征上。把 18 个站点不带站点条件地池化进一个模型，比 18 个独立模型差 0.36 °C。

1 引言

公开气象数据集很容易诱出一个看似轻松的基准题：用今天的观测预测明天的气温。在本文所用的数据集上——18 个欧洲站点、十一年的逐日观测——“明天等于今天”这条规则在原始日均温上就能做到测试 MAE 1.667 °C、 $R^2 = 0.9206$ 。而仅月度气候均值一项就解释了这条序列 74.4% 的方差。于是任何回归模型，无论多么简单，都能在原始目标上刷出高准确率，而这个数字证明的是日历与大气惯性，不是模型。

把这些免费技巧拿掉之后，剩下的才是值得问的问题。我们重新定义任务，使那些平凡预报在构造上就不携带任何信息，并把巴塞尔日最高温的日际变化 $\Delta T_{\max}(t+1)$ 定为目标。在这个空间里持续性预报恒为零，超出这条线的精度只能来自大气本身。

可用的信号在上游。差分已经去掉了季节循环，而与巴塞尔次日变化关系最强的同日预测因子是别处的观测：在日均温变化上，马斯特里赫特、图尔与德比尔特的相关达到 0.35 - 0.40；在本文采用的最高温变化上，图尔以 0.35 领先，随后是马斯特里赫特 0.20 与德比尔特 0.19。第 3 节到第 5 节度量这些信号有多少能进入拟合好的模型，又以什么形式存在。

2 数据集

本文使用 Huber 等人发布的气象预测数据集（MIT 许可），观测源自欧洲气候评估数据集 ECA&D，取 release commit 83d70ee。主表覆盖 2000-01-01 至 2010-01-01 连续 3654 天、18 个欧洲站点，含 DATE、MONTH 两列与 163 个特征。它们对应 18 站 $\times$ 11 个变量（温度、湿度、气压、风、辐射、日照、云量、降水）；理论上应有 198 个站点-变量格子，实际有 35 个整体缺失。wind_gust 只覆盖 7 个站点，巴塞尔既不报风速也不报阵风。

上游已做的加工

这份发布数据的“干净”只是构造意义上的。缺失率超过 5% 的列被整列删除；缺失率不超过 5% 的列由数据集作者做均值填补。两项操作上游都有文档说明，而且在这里都重要：均值填补会压缩方差、抬高受影响列的相关性，而整列删除丢掉了真实但稀疏的信息，例如阵风。单位异质是刻意保留的：气压以 1000 hPa 为单位，水平列的标准差约 0.008，其变化约 0.005；湿度取值 0 到 1；阵风可达 41 m/s。所以对基于距离或梯度的模型而言，标准化不是可选项。

物理合理性审计

由于上游的填补是用数值填掉缺陷而不是把它们标记出来，每一个格子都按物理取值范围检查过。共有 77 个值不可能出现：三个 STOCKHOLM_cloud_cover 格子（两个 -99 哨兵值，一个 9 oktas 超出 0-8 的范围）、斯德哥尔摩 29 天日照为负、四个 -0.099 或 0.0003 的气压值，以及 41 天 temp_min 大于 temp_max（希思罗 40 天、罗马 1 天）。它们占 595,602 个格子的 0.013%，损害集中在两个站点而非均匀散布。其中一个缺陷格——斯德哥尔摩云量，2009-06-25——落在测试期内，留着它就会把一个损坏的日子放进评估集。差分会把这类值放大成受影响单位下量级 100 的假象，所以要在取任何差分之前先移除。

结构

巴塞尔日均温的月度气候均值解释其方差的 74.4%，去季节化异常的一阶自相关为 0.819；而变化序列接近白噪声：其 lag-1 自相关在 T_mean 上是 +0.07，在 T_max 上是 -0.08。特征矩阵高度冗余，163 个特征中有 62 个属于 $|r| > 0.95$ 的相关对，最强的一对是 0.996，出现在两个相邻站的气压之间。剩下可用的技巧来源只能是跨站点信息，因为目标站自身当日变化与其次日变化的相关只有 -0.08。

3 问题形式化

3.1 三个候选目标与各自的难度地板

对一条气温序列而言，预测问题会随预测对象的不同而发生质变。表 1 给出每个候选目标的难度地板，以及在它上面拿到高分究竟证明了什么。

表 1 巴塞尔次日气温预测的三个候选目标，以及在每个目标上拿到高分分别证明了什么。

目标	季节循环占比	持续性成绩	高分证明的是
原始 $T_{\text{mean}}(t+1)$	方差的 74.4%	MAE 1.667 °C ($R^2 = 0.9206$)	日历 + 惯性
去季节化异常	设计上已剔除	RMSE 2.288 °C	异常持续性
$\Delta T_{\text{max}}(t+1)$	构造上 ≈ 0	MAE 2.393 °C (零变化)	气象学，如果有的话

预测原始值会同时调用两个技巧来源。预测异常去掉了日历，却留下异常持续性，而持续性预报本来就已把它拿走了：持续性 RMSE 2.288 °C，气候距平零假设 3.378 °C。这两个数字来自一次规模更小的探索性拟合，用的是未清洗数据、scikit-learn 岭回归与 T_{mean} 距平目标；它们说明的是效应量级，而不是一个能与表 2 各列并排的 MAE。预测变化把两个来源同时去掉，代价是上限大幅降低，因为接近白噪声的目标撑不起高分。

3.2 形式化定义

令 $x_t \in \mathbb{R}^{163}$ 收集第 t 天全部 18 个站点的原始观测，并附加第 4.2 节描述的工程特征块。目标为

$$y_t = \Delta T_{\text{max}}^{\text{BASEL}}(t+1) = T_{\text{max}}^{\text{BASEL}}(t+1) - T_{\text{max}}^{\text{BASEL}}(t), \quad \text{式 (1)}$$

我们通过最小化经验风险 $(1/n) \sum_t \ell(f(x_t), y_t)$ 学习 $f: \mathbb{R}^p \rightarrow \mathbb{R}$ ，其中 ℓ 对线性模型取平方误差、对 MLP 取 Huber 损失，另加一个可选惩罚项。之所以用 T_{max} ，是因为 18 个站点都有它，而 temp_min 缺布达佩斯。

3.3 等价性论证：把持续性移进评价

换目标并没有换假设空间。当 $T_{\text{max}}(t)$ 本身就在输入里时，任何对明天气温水平的预测器减去这个输入，就变成对变化的预测器；反过来也成立，两个任务共享同一个假设空间。变的是评价。

在水平空间里最强的基线是持续性， $\hat{T}(t+1) = T(t)$ ，每个模型都要与它对照。在变化空间里，同一条基线变成常数零，于是持续性技巧被构造性地从每个模型身上剥离。这个等式是精确的：一个只是复制 $T_{\text{max}}(t)$ 的模型，在水平空间里 MAE 是 2.393 °C；在变化空间里零预报恰好也是 2.393 °C，因为变化正是两个水平之差，误差在两种写法下是同一个量。重新形式化改变的是：基线成了分数的一部分，而不是一次单独的对照，于是模型无法靠继承日历与大气的惯性而显得准确。

3.4 其他备选任务

有六个备选目标被搁在一边。次日原始气温受持续性污染，而且已经被数据集自带的教学 notebook 与公开 kernel 覆盖。日照时长回归正是那些 notebook 的主实验。野餐适宜性与月份分类是派生标签：野餐标志是一条确定性规则（“无雨且暖”），有一个站点恒为 False，逐月正例率跨越两个数量级，于是随机划分会把任务退化成猜日历。降水量每站有 35 - 75% 的零膨胀，需要 hurdle 式处理。次日降水是否发生是一个合理的低技巧扩展，纯粹出于范围考虑留待后续。

3.5 评估协议

切分。原始日温 lag-1 自相关 0.957，任何随机划分都会泄漏。本文使用唯一的固定时间切分：训练 2000 - 2007（2922 天，对齐后 2920 个样本）、验证 2008（366）、测试 2009-01-01 至 2010-01-01（366）。最后一天只是一个边界观测，所以这个窗口实质上是 2009 日历年加一天。掩蔽按目标日期定义，因此训练样本的标签仍落在训练期内。验证年份决定每一个模型与超参选择。

统计量只用训练期。清洗阈值、填补中位数、标准化参数、月度气候均值与正则化强度，全部在 2000 - 2007 上估计，再原样施加到 2008 与 2009。

指标。主指标是 MAE ($^{\circ}\text{C}$)，因为目标重尾：锋面过境产生 $|\Delta T_{\max}| > 10^{\circ}\text{C}$ ，测试期最大的单次变化是 11.9°C 。同时报告 RMSE、变化空间的 R^2 、预测变化与实测变化的 Pearson 相关（近常数预报下无定义，记为“—”），以及

$$\text{技巧 skill} = 1 - \text{MAE}_{\text{模型}} / \text{MAE}_{\text{零变化}}, \quad \text{式 (2)}$$

即相对零变化基线的 MAE 相对降幅。

不确定性。测试期 366 天，独立抽样下 MAE 的标准误约 0.11°C ，在本文实际使用的 7 天分块 bootstrap 下约 0.15°C ，因此零点几摄氏度的差异是边缘的。所有区间都是 7 天块的移动块 bootstrap 95% 置信区间，选 7 天是因为天气尺度系统会持续好几天，重采样 1000 次，随机种子固定。两个模型之间的差异在同一批重采样块上做配对 bootstrap，这大致把差值上的噪声减半，比较两条边际区间更灵敏。测试指标按每个模型族最终选定的配置计算；MLP 网络的测试列为透明起见报告了全部 12 个配置，它没有参与选择。

4 模型

4.1 数据管线

所有模型共用一条管线。物理上不可能的格子在任何差分之前先掩蔽为 NaN，这样哨兵值就不会在 delta 特征里变成量级 100 的尖刺。被掩蔽与缺失的格子随后用训练年份估计的“按站点、按日历年”中位数填补。特征从清洗后的表构造，用训练集均值与标准差标准化，然后送入模型阶梯。

第 2 节的审计数出 77 个缺陷值，但掩蔽移动的格子比这个多：41 个 temp_min 大于 temp_max 的日子里，每一个都会让两个成员同时变空，因此最终共 118 个格子被置为 NaN。两个成员都清掉，是因为在一对矛盾值里保留一个，比两个都丢掉更糟。

4.2 特征块

- **levels** (163)：第 t 天的全部观测，标准化。
- **deltas** (163)：同一批列的一日差分， $x_t - x_{t-1}$ 。变化特征承载天气系统信号。
- **grads** (7)：巴塞尔上游七个站的气压减去巴塞尔气压。这七站是马斯特里赫特、图尔、杜塞尔多夫、明兴、卡塞尔、德比尔特与希思罗，在任何建模之前就由一个领先相关探针固定下来。该探针按

各站水平异常与巴塞尔异常的次日相关排名，这七站在其中得分 0.69 - 0.80；六座按名次取，希思罗按西风带上游位置入选，被落下的是排在第七的蒙泰利马尔（0.695）。若改用与变化目标的相关给同一批站排名，顺序就不同了，蒙泰利马尔（0.110）与佩皮尼昂（0.125）会反超明兴（-0.071）与卡塞尔（0.067）。所以这个集合是一个物理上的选择，而不是变化目标单独会给出的那一个。

- **受控项，默认关闭：**日序 $\sin/\cos(2)$ 与缺失指示（163）。它们只作为消融实验臂出现，因此主配置里没有任何日历信息进入。

主输入是 `levels + deltas`, $p = 326$ ；加上 `grads` 得 333。另有两个缩减输入供消融使用：上游 7 站子集（14 列，即上游 $T_{\max}$ 的水平与差分）以及本站点对（巴塞尔 $T_{\max}$ 的水平与差分， $p = 2$ ）。

4.3 模型阶梯

基线。零变化预测 $\hat{y} = 0$ ，并设定式（2）的准入线。昨日 Δ 重复今天的变化；它应当失败，而它的失败正好记录了变化序列没有可利用的自相关。月度 Δ 气候值用训练期按日历月求的平均变化，技巧应当在零附近。

岭回归，闭式解。对每个特征集，我们精确求解

$$\hat{w} = \operatorname{argmin}_w \|Xw - y\|_2^2 + \alpha \|w\|_2^2 = (X^T X + \alpha I)^{-1} X^T y, \quad \text{式 (3)}$$

求解通过 `torch.linalg.solve` 完成。没有学习率、没有轮数、没有随机初始化，所以答案精确到机器精度，每次运行都完全相同。唯一的超参 α 在从 10^{-2} 到 10^4 的 25 点对数网格上，按 2008 年的验证 MAE 选取。输入与目标都做了均值中心化，截距不参与惩罚，所以惩罚只作用在 w 上。

式（3）丢掉了均方风险里的 $1/n$ ；这只是相对式（1）的约定重新标定了 α ，而网格是搜索出来的，不是固定的。2920 个训练样本、 $p \leq 333$ 时求解瞬时完成，这让数百次正则化拟合既廉价又完全可复现。

Lasso。 L_1 版本 $\operatorname{argmin}_w \|Xw - y\|_2^2 + \alpha \|w\|_1$ 没有闭式解，用 Adam 训练 200 轮， α 在 2008 上从 $[10^{-3}, 1]$ 的 8 个几何取值中选取。它与式（3）用同一套均方误差约定，并充当第二种正则族。作为选择工具它并不成立：在验证最优的 α 下，326 个系数里只有 2 个低于 10^{-4} 的数值阈值，所以这个拟合是一个换了正则化方式的线性模型，而不是稀疏模型。

MLP。一个小型前馈网络，隐藏层规模取 {32}、{64, 32} 或 {128, 64}，GELU 激活，`dropout` $\in \{0.2, 0.4\}$ ，权重衰减 $\in \{10^{-4}, 10^{-3}\}$ ，共 12 个配置。训练使用 Huber 损失， $\delta = 1$ ，目标按训练期 σ_Δ 标准化，Adam 学习率 10^{-3} 、batch 64，并在验证 MAE 上早停，耐心 30，最多 300 轮。每个配置跑三个固定种子 {0, 1, 2}，按平均验证 MAE 选取，报告的测试数字是三个种子预测的均值。

多站点扩展。18 个站的变化序列被堆叠成 65,736 个 station-day (18×3652 个对齐日，其中测试片 6588 个)，每个样本都带着同一个全局 326 列特征场，以及目标为它自己站点的 $\Delta T_{\max}$ 。变化空间移除了各站气候态，这正是池化在这里物理上可接受、而在水平空间里从来不可接受的原因。

全部工作在 PyTorch 2.13 加 CUDA 下完成，随机种子全程固定：`bootstrap` 用 42，Lasso 的梯度拟合用 0，MLP 用 {0, 1, 2}。有一处不一致值得点出来。MAE 是评分指标，而它的最优预测量是条件中位数；线性模型用最小二乘估计的却是条件均值，MLP 的 Huber 损失在中心区域也退化成均值。惩罚强度同

样按验证 MAE 挑选，而拟合本身最小化的是平方误差。这并不使比较失效，因为所有模型都按同一种方式评分，但它确实意味着每个模型都不是在拟合它被评判的那个损失。

5 实验

5.1 主要结果

表 2 巴塞尔 $\Delta T_{\max}(t+1)$ 的测试期结果，2009-01-01 至 2010-01-01（366 天）。MAE 单位 $^{\circ}\text{C}$ ，括号内为 95% 移动块 bootstrap 置信区间（7 天块、1000 次重采样）。技巧按式（2）定义；相关为预测变化与实测变化的 Pearson 相关。

模型	MAE [95% CI] ($^{\circ}\text{C}$)	RMSE ($^{\circ}\text{C}$)	R^2	相关	相对零变化技巧
零变化（及格线）	2.393 [2.104, 2.680]	3.176	0.000	—	—
昨日 Δ	3.447 [3.033, 3.916]	4.647	-1.141	-0.072	-44.0%
月度 Δ 气候值	2.393 [2.098, 2.682]	3.174	0.001	0.034	+0.0%
岭回归：仅 levels（163）	1.845 [1.651, 2.033]	2.383	0.437	0.665	+22.9%
岭回归：levels+ Δ （326）	1.827 [1.623, 2.014]	2.400	0.429	0.660	+23.7%
岭回归：levels+ Δ +grad（333）	1.829 [1.624, 2.012]	2.410	0.424	0.660	+23.6%
岭回归：上游 7 站子集（14）	2.056 [1.829, 2.284]	2.760	0.245	0.502	+14.1%
岭回归：仅本站（2）	2.392 [2.104, 2.675]	3.152	0.015	0.183	+0.0%
Lasso：levels+ Δ （326）	1.773 [1.574, 1.955]	2.365	0.445	0.671	+25.9%
MLP 集成（最佳配置）	1.751 [1.546, 1.946]	2.341	0.457	0.682	+26.9%




图 1 测试窗口（366 天）上的模型阶梯。柱高为测试 MAE ($^{\circ}\text{C}$)，须为 95% 分块 bootstrap 置信区间。灰色：朴素基线；蓝色：岭回归各变体；橙色：Lasso；红色：MLP 集成。虚线标出 2.393°C 的零变化及格线。

三个学习模型都优于零变化基线，配对 bootstrap 差值稳稳小于零（表 3），所以这份技巧不是波动。学习模型之间的差异则不显著：MLP 相对岭回归改进 0.076 °C，95% 区间为 [-0.149, 0.000]。信息比模型类别更要紧。全量场相对上游 7 站子集有显著的 0.229 °C 优势，而目标站自身的温度观测给出 +0.0% 技巧。




图 2 左：测试窗口上 MLP 集成的预测对实测 $\Delta T_{\max}$ (MAE 1.75 °C, $r = 0.68$)；中等幅度的变化被捕捉到，极端值被收缩。右：逐月误差剖面（测试期 2009 年，366 天，单位 °C）；零变化基线（灰）与 MLP（红）都在晚春和夏季误差最大，那里平均绝对变化也最大，在秋冬最小。

图 2 左的收缩不是 MLP 的缺陷。一个无法解析单次锋面过境之驱动因子的模型，最小化期望损失的正确做法恰恰就是收缩。收缩所做的，是给可达的 MAE 划了一条上限，同时它指向季节结构：模型与基线之间的技巧差距在平均绝对变化最大的月份最宽，在这个测试年里落在晚春与夏季（图 2 右）。

5.2 配对显著性

表 3 测试 MAE 的配对分块 bootstrap 差值 (A - B, 单位 °C; 负值表示 A 更优)。“显著”指区间不含零。

A - B	差值 (°C)	95% CI	显著
MLP - 零变化	-0.642	[-0.843, -0.467]	✓
Lasso - 零变化	-0.620	[-0.834, -0.416]	✓
岭回归(1v1+Δ) - 零变化	-0.566	[-0.769, -0.383]	✓
MLP - 岭回归(1v1+Δ)	-0.076	[-0.149, 0.000]	
MLP - Lasso	-0.023	[-0.119, 0.068]	
Lasso - 岭回归(1v1+Δ)	-0.054	[-0.101, 0.002]	
岭回归(1v1+Δ) - 岭回归(up7)	-0.229	[-0.367, -0.115]	✓

MLP 对岭回归的区间在上界恰好触零，所以 MLP 与“在线性之上没有改进”是一致的。在 366 个测试日上，低于约 0.1 °C 的效应无法分辨。

5.3 特征消融

表 4 同一协议下的特征集消融；除注明外均为岭回归。维数是输入列数，MAE 单位 °C。

特征集	维数	MAE (° C)	技巧
仅 levels	163	1.845	+22.9%
仅 deltas	163	1.978	+17.4%
levels + deltas (主配置)	326	1.827	+23.7%
+ 气压梯度	333	1.829	+23.6%
+ 梯度 + 日序 sin/cos	335	1.834	+23.4%
+ 梯度 + 缺失指示	496	1.842	+23.0%
上游 7 站: levels + deltas	14	2.056	+14.1%
上游 7 站: 仅 deltas	7	2.115	+11.6%
上游 7 站: deltas + 梯度	14	2.075	+13.3%
本站: 水平 + 差分	2	2.392	+0.0%
Lasso 全量 (326)，按验证选 α	326	1.773	+25.9%
Lasso top-25 特征，岭回归重拟合	25	1.859	+22.3%

levels 与 deltas 各自单独就承载了大部分信号，彼此叠加增益有限，单独是 22.9% 与 17.4%，合并是 23.7%，这说明两块在很大程度上编码的是同一批天气系统。加入日序特征把技巧降到 23.4%，这就是变化目标里没有日历免费午餐的证据。气压梯度在全量场面前是冗余的，23.6% 对 23.7%；但在上游子集内部它有价值，11.6% 升到 13.3%，所以它携带的是部分重叠的信息。

缺失指示这一臂几乎没有信息量。最多只有 595,602 个格子中的 118 个可能被标记，即 0.02%，这样规模的实验臂几乎没有统计功效。118 个缺失格里有三个来自我们掩蔽过的列：图尔气压一个格子在 2008 年，因此只影响验证期的预测；斯德哥尔摩气压三个格子全都落在训练窗口内。它们的变化列分别继承了 2 个和 6 个填补值，不足 0.02% 的行，用训练期中位数填上。测试期唯一的缺陷在差分之前已被移除。

稀疏性给出一个紧凑的核心。在 Lasso 的 top-25 特征上重拟合岭回归，保留了全模型 23.7 个百分点技巧中的 22.3 个，也就是一个 25 特征的模型几乎容纳了全部技巧。但 Lasso 本身在验证最优的 α 下仍保留 326 个系数里的 324 个非零，所以信号是分布在整个场上的，而不是集中在少数几个通道。

5.4 权重质量落在哪里




图 3 按原始单位绝对值最大的 15 个 Lasso 系数，以标准化尺度作图（测试窗口 2009 年，366 天）。蓝：正，橙：负。15 个里有 14 个是气压特征，在巴塞尔与其他站点都有；唯一的例外是马斯特里赫特的湿度变化。

图 3 显示了这个拟合倚重什么。按标准化幅度排序，这 15 个里最大的几个是希思罗的气压日变化（-0.30）、巴塞尔（+0.28）与蒙泰利马尔（+0.23），图尔的气压水平值（-0.17），马斯特里赫特的湿度变化（+0.13），希思罗的气压水平值（-0.12）与巴塞尔的气压水平值（+0.10）。

有两件事限制了这张图能承载的结论。这 15 个是按原始系数幅度挑出来的，而气压的原始标准差只有 0.008，所以它部分上是靠单位爬上来的。能站住的结论关乎整体的权重质量，而不是任何单一通道。在 326 个已标准化且近乎共线的输入上，每个 $\alpha > 0$ 的极小值点都是唯一的，可数据分不开那些近乎共线的替代方案，所以没有哪个单独的系数是稳定可解释的。

5.5 MLP 网格

网格是平的。跨约 10.5k 到 50k 的参数范围，每个配置的测试集成 MAE 都落在 1.70 到 1.75 °C 之间。按验证选出的配置是隐藏层 64 - 32、dropout 0.4、权重衰减 10^{-4} ，平均验证 MAE 1.797 °C；它的逐种子测试 MAE 为 1.795、1.758 与 1.757 °C（种子标准差 0.018），三个种子集成后是 1.751 °C。在这个样本量上，容量不是约束瓶颈。

5.6 多站点扩展

表 5 多站点扩展，2009 年测试期 6588 个 station-day。按站模型是 18 个在全量场上独立拟合的岭回归；池化模型是单一全局拟合，以各站为目标，输入里没有站点身份。本表的技巧是相对池化零变化及格线测得的；图 4 用的是各站自己的及格线，因此两者不能直接比较。

模型	MAE (° C)	95% CI	相对池化零变化技巧
池化零变化	2.187	—	—
按站岭回归（18 个模型，均值）	1.705	[1.299, 1.998] [†]	+22.0%
池化岭回归（单一全局模型）	2.066	[2.016, 2.115]	+5.5%
池化 MLP	2.038	[1.986, 2.088]	+6.8%

[†] 该区间是各站之间的取值范围，不是 bootstrap 置信区间。




图 4 各站测试 MAE（每站 366 天，单位 ° C）：零变化基线（灰）对比每站一套的独立岭回归（蓝），按基线难度排序。18 个站的技巧全为正，从希思罗的 +6.7% 到明兴的 +31.4%。

池化要付精度的代价。单一全局岭回归做到 2.066 ° C，而 18 个独立模型是 1.705 ° C，0.36 ° C 的差距超过了池化模型自身的区间，也高于最好的单站水平。池化 MLP 把差距收回一部分，到 2.038 ° C。

机制是站点特异性。每个站的变化序列通过自己的坡向、海拔与大陆性响应同一个天气尺度场，一组权重向量无法表达 18 个不同的响应向量。这个限定很重要：输入里没有站点标识，于是对线性模型而言这种失败近乎注定。要精确恢复那些独立模型，需要每站一条独立的斜率向量，也就是 18 组“站 × 特征”交互列，而不是 one-hot 站点列，后者只给出站点特定的截距。这个实验排除的是无条件参数共享，不是一般意义上的共享表示。池化 MLP 收回了一部分差距，提示站点信息在没有显式标识的情况下也是可恢复的，不过本报告没有定位它在哪里。能定论的那个对照实验——共享主干加各站独立的输出头——没有跑。

6 讨论与局限

三个学习模型聚集在 24 - 27% 的技巧上，彼此差异在统计上不可分辨。我们把这个平台看作任务的性质，而不是模型的性质。一旦持续性与日历被移除，剩下的多数是日提前尺度上的天气尺度噪声，而现有信息支持的大约就是四分之一的 MAE 降幅。两个失败的基线指明了信号不在哪里：它在空间场里，而不在目标自身的历史里。MLP 相对精确线性解的优势也落在同一份噪声之内。验证曲线里没有任何东西指向更深处，因为在第 5.5 节那 12 个配置上验证 MAE 不随容量下降，测试 MAE 的跨度只有 0.05°C 。被选中的配置事实上是 12 个里测试最弱的一个，这正是在差异如此之小时按验证集选型所买到的东西。在这个范围内，网络与线性解在噪声之内是同一个预测器，而 366 个测试日分不开它们。

上游加工值得算一笔清楚的账。对稀疏列的均值填补会压缩方差，并且恰好抬高这些列的相关性；我们对被掩蔽格子做的按站点按月中位数填补是第二次这样的操作，作用在 0.02% 的格子上。上游那次填补是另一回事：它填过的每一列里最多触及 5% 的格子，总量没有被记录下来，也正因为如此，第 2 节的缺陷审计必须从头重跑一遍。

局限。366 天的窗口限定了可以主张的范围，低于约 0.1°C 的效应够不着。6588 个 station-day 的多站点堆叠功效更大，但它回答的是另一个问题，即逐站响应的异质性。大约三十个配置是在这一个窗口上打分的，没有做多重比较校正，所以本文报告里由哪个模型族领先是一个事后选择。所有预处理统计量都只用训练期，但特征构造这一环要弱一些：一天差分窗口是在看过 2009 - 2010 目标上的 horizon RMSE 之后才定的，这是测试信息唯一一次进入设计。站点排名只用了训练窗口内的相关，选择过程中没有在测试数据上拟合任何模型，但一个完全留出的区域会更干净。除此之外，本研究覆盖的是一个目标站与一个测试年：图 4 的逐站分析谈的是跨站点的普适性，而不是跨年份，而 $T_{\max}$ 序列是同质化处理后的产品，我们把上游的质量控制当作既定事实接受。

关于平流解读。上游的优势和权重质量集中在气压上这两件事，都与中纬度平流相符，也同样与一个无方向的空间信号相符。这里的任何测试都分不开这两种读法。最直接代理沿流结构的气压梯度特征，在全量场面前不增加任何东西，这一点若要说的话反而对平流解读不利。要定论，可以算地转风并与域平均气压基线比较。多提前步的技巧衰减， $h = 1 \cdots 10$ ，能定量刻画可预报性边界；次日降水是否发生是同一协议下自然的低技巧分类扩展；而池化的结果直接指向把单一全局模型换成站点条件的输出头。

7 结论

预测日际变化而不是水平值，把持续性与季节循环从奖励函数里移除，并让零变化预报成为一条显式的及格线。在按时间的切分、只用训练期统计量、带分块 bootstrap 不确定性的协议下，一组刻意简单的模型在测试年上取得 24 - 27% 的 MAE 技巧。岭回归是 1.827°C ，Lasso 是 1.773°C ，MLP 集成是 1.751°C ，而零变化是 2.393°C 。相对基线的每一项改进都是显著的，学习模型之间的每一处差异都在噪声之内。信号是空间性的，权重偏向气压。目标站自身的温度一点也带不来它，而它自身的气压却属于最强的单一预测因子之列。

让这个结果可用而不只是分数好看的，是上述每一条陈述都是一个带区间的、可证伪的数字，其中还有好几条指向相反的方向：MLP 增益上的零结果、冗余的梯度特征、以及那个只在没有站点条件时才成立的池

化结果。

数据可得性

数据集为公开、MIT 许可：github.com/florian-huber/weather_prediction_dataset，release commit [83d70ee](https://github.com/florian-huber/weather_prediction_dataset/commit/83d70ee)，Zenodo 存档 [doi:10.5281/zenodo.7525955](https://doi.org/10.5281/zenodo.7525955)。代码与机器可读结果随本报告附上；附录 A 列出重新生成每张表与每幅图的脚本。

参考文献

[1] Klein Tank, A. M. G., 等 (2002)。面向欧洲气候评估的 20 世纪地表气温与降水逐日数据集。 *International Journal of Climatology*, 22, 1441–1453.

[2] Huber, F., van Kuppevelt, E. D., Steinbach, P., Sauzé, C., Liu, Y., Weel, B. (2023)。Will the sun shine? — An accessible dataset for teaching machine learning and deep learning. *Proceedings of the Third Teaching Machine Learning and Artificial Intelligence Workshop*, PMLR 207, 27–31.

附录 A 可复现性

环境。Python 3.12, PyTorch 2.13 加 CUDA, NumPy 与 pandas; scikit-learn 只出现在提前步与站点探针里。全程没有随机划分，随机种子按第 4.3 节所述固定。

重新生成结果。把数据集 CSV 放到 `data/` 下，在仓库根目录执行：

```
python analysis/eda.py                (第 2 节的数据审计)
python analysis/formulation_probe.py   (提前步衰减与上游站点相关; 表 1、第 4.2 节)
python analysis/delta_t_probe.py       (变化目标的敏感性)
python analysis/r1_baselines.py        (管线与基线表)
python analysis/r2_lasso_ablation.py   (表 4, 以及图 3 的系数)
python analysis/r3_mlp.py              (MLP 网格, 第 5.5 节; 表 5)
python analysis/r4_eval_figures.py     (表 2–表 3, 图 1–图 4)
```

每个脚本把自己的表写成 CSV，本报告里的每一个数字都能追溯到这些文件之一。

数据归属。观测来自 ECA&D 站点数据 [1]；数据集与背景见 Huber 等人 [2]。上游加工已在第 2 节描述：缺失率超过 5% 的列被删除，其余做均值填补，单位被缩放但未标准化。

本中文版为英文报告 `report.pdf` 的完整对照译本，仅供作者内部理解与答辩准备使用；所有数字与英文版逐项一致。正式提交以英文版为准。